

테스트 계획 및 결과 보고서

4 조


김진남, 정민규, 정주애, 천성배

1. 개요 및 테스트 목적

본 보고서는 LangGraph 및 하이브리드 RAG 기반 전·월세 분쟁 팩트체커 시스템의 기능적 정확성과 시스템 안정성을 종합적으로 검증하기 위한 테스트 계획 및 결과 분석을 다룬다. 본 시스템은 복잡한 임대차 관련 법령, 대법원 판례, 주택임대차 분쟁조정위원회 사례를 아우르는 고도화된 지식 베이스를 기반으로 작동한다. 본 테스트는 사용자 입력의 의도 분류 파트부터 데이터 적재 검증, 최종 근거 기반 답변 생성의 환각 여부까지 전 과정을 정량적으로 검증하여 시스템의 실무 적용 가능성을 평가하는 것을 목적으로 한다.

2. 테스트 환경 및 대상

- 테스트 대상 모듈: graph.py, vs_method.py, ocr_get_text.py
- 인프라 및 프레임워크: Python 3.13 / LangGraph / Supabase / OpenAI gpt-4.1-mini, gpt-4o
- 모니터링 및 추적 도구: LangSmith
- 품질 평가 프레임워크: Ragas 지표 준용.



3. 정량적 성능 평가 결과 (Ragas 지표)

검증 세트에 대해 파이프라인을 작동시켜 획득한 Ragas 프레임워크 핵심 스코어 및 LangSmith 기반 실제 수행 래턴시 데이터는 다음과 같다.

RAGAS 평가지표	평가점수	현재 RAG 시스템 상태 진단
Faithfulness(충실도)	0.713	안정적(할루시네이션 통제 성공) LLM 이 주어진 법률 근거 내에서 71%이상의 높은 확률로 팩트에 기반한 답변 생성
llm_context_precision _without_reference	0.719	사용자 질문에 필요한 핵심 법률과 판례 청크들이 검색 결과에 높은 정확도로 먼저 배치되고 있다.

4. 주요 문제점 및 트러블슈팅 (조치 사항)

- **[발견된 에러 및 현상]:** 시스템 파이프라인 테스트 초기 단계에서, Supabase DB 내부에 마크다운 표 구조를 지닌 정규 청크 데이터를 온전하게 적재 완료했음에도 불구하고 스트림릿 채팅 UI 창에서 질문 입력 시 관련 법률 및 판례 데이터를 전혀 연동해오지 못하는 심각한 누락 현상(retrieved = 0 건)이 무작위적으로 발견됨.
- **[원인 정밀 진단]:** vs_method.py 모듈의 search_similar 함수가 메타데이터 필터링을 수행할 때, 쟁점 태그(issues) 배열을 이중 리스트 형태([[]])로 래핑하여 PostgreSQL JSONB Containment(@>) 연산자로 전달하고 있었음. 이로 인해 DB 에 실제로 1 차원 리스트 구조({'issue': ['중개']})로 저장된 메타데이터 스키마와 데이터 차원 불일치가 발생하여, 벡터 유사도 연산을 거치기도 전에 SQL 쿼리단에서 데이터가 차단된 것임 확인.
- **[기술적 조치 완료]:** 1) vs_method.py 내부의 issues 필터 매핑 구조에서 이중 배열을 제거하고, 원소 단위 1 차원 JSONB 배열 포함 검사(Json({'issue': [t]}))로 변환 쿼리를 패치하여 스키마 동기화 완료. 2) 파이프라인 검색 안정성을 확보하기 위해 graph.py 상단에 USE_FILTERS = False 폴백 모드를 신설, 메타데이터 태그 미스매치 임계 상황 발생 시에도 순수 임베딩 스페이스 코사인 유사도 점수 기반으로 문서를 정상 반환하도록 아키텍처 다중화 완료.

5. 결론 및 향후 계획

본 프로젝트를 통해 구축된 시스템은 LangGraph 프레임워크 기반의 상태 관리 에이전트 아키텍처와 pgvector 의미론적 검색(Semantic Search) 결합을 통해 세입자에게 신뢰할 수 있는 전·월세 분쟁 예방 지식을 전달할 수 있는 프로세스를 완성하였다. 특히 Ragas 검증 결과를 통해 입증된 환각 차단 메커니즘은 본 시스템의 가장 강력한 핵심 경쟁력이다. 또한 마스킹과 LLM의 성능향상을 하여 개인정보 문제를 해결할 계획이다.